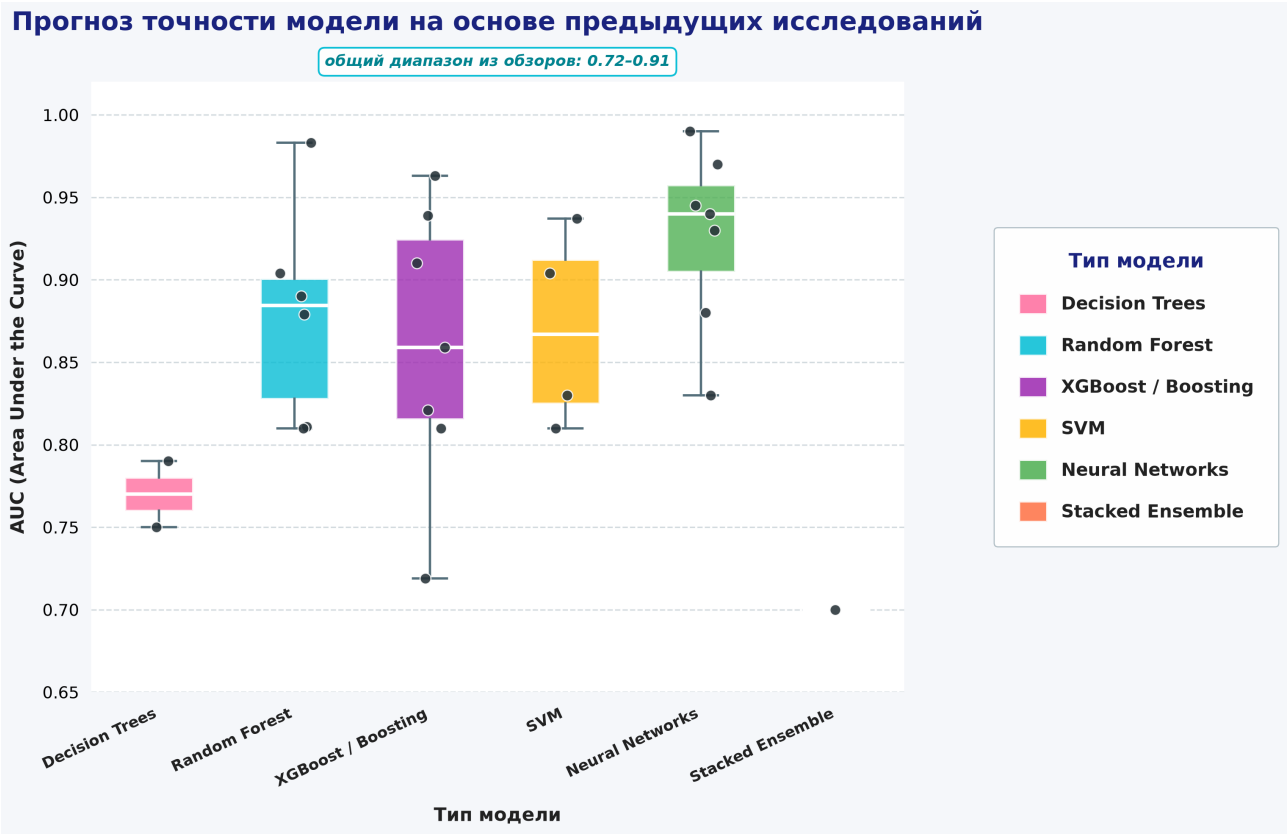
1. ОТЧЕТ ОБ MVP

1. Отчет об исследовании
1.1. Цель и исследовательский пробел
1.2. Данные
1.3. Постановка и методология
1.4. Основные результаты
1.5. Аудит утечек данных
1.6. Ограничения
1.7. Выводы и рекомендации

2. Краткая характеристика ML-сервиса
2.1. Название, тип и назначение
2.2. Пользователи сервиса
2.3. Входные данные
2.4. Выходные данные
2.5. Модель и признаки
2.6. Качество на синтетическом пилоте
2.7. Схема интеграции
2.8. Жизненный цикл сервиса
2.9. Ключевые ограничения

1.1. Цель и исследовательский пробел

Цель работы — проверить возможность раннего выявления риска профессионального выгорания педагогов по данным региональной государственной образовательной ГИС СО «ЕЦП» и оценить, дает ли ML-модель сигнал сверх простого бейзлайна.



По обзору литературы существующие работы прогнозируют выгорание в основном на специально собранных опросных данных, на ограниченных административных выборках или на вторичных и синтетических датасетах. Ключевой пробел: ни одна из рассмотренных работ не использует данные региональной государственной образовательной ГИС как источник предикторов. Настоящий проект закрывает этот пробел: ML-сервис встраивается как внешний прогнозный модуль через шину ГИС СО «ЕЦП», не вмешиваясь в ядро системы.

1.2. Данные

Использован синтетический датасет — симулятор выгрузки ГИС СО «ЕЦП». В нем 10 761 строка панели «педагог × неделя», 295 педагогов, 1 597 строк с целевой меткой. Положительный класс burnout_level >= 2 — 119 строк, доля 7,5 процента.

Целевая переменная burnout_level соответствует фазам Бойко: 0 — нет признаков, 1 — напряжение, 2 — резистенция, 3 — истощение. Для бинарной постановки использован риск «средне-высокий»: burnout_level >= 2.

В симуляторе заложены S-образная динамика выгорания, AR(1)-шум, сезонность и школьные шоки, усталость от волн опросов, смещение неответа при высоком латентном уровне, найм и увольнения, в том числе зависимость увольнений от уровня выгорания.

Важно: метка есть только в недели опросов, поэтому модель предсказывает наблюдаемую метку самоотчета, а не латентное состояние педагога. Корреляции в датасете — следствие генератора, а не доказательство причинности.

1.3. Постановка и методология

Решалась задача бинарной классификации: предсказать риск burnout_level >= 2 для педагога на той же неделе, где доступна метка опроса.

Использованы признаки: сырые поведенческие event_hours, activity_hours, act_avg_participants_per_hour, act_msg_cnt, act_msg_char_cnt; инженерные rolling-средние за 4 и 12 недель, отклонение от базовой медианы первых 6 недель, дельты, лаги, chars_per_msg; история таргета prev_level, past_level_mean, past_level_max, n_past_surveys, has_prior; сезонные week_of_year, month, tenure.

Основная модель — RandomForest с медианной импутацией и class_weight balanced_subsample. Подбор гиперпараметров: RandomizedSearchCV, GroupKFold(3). Финальная валидация: GroupKFold(5) по user_id, чтобы один педагог не попадал одновременно в train и test.

Лучшие параметры RF: n_estimators=221, max_depth=12, max_features=0.5, min_samples_leaf=25, min_samples_split=2.

1.4. Основные результаты

Финальная RF-модель на 5-fold GroupKFold показала ROC-AUC 0,8824; PR-AUC 0,6983; Brier score 0,0590. При пороге 0,5 precision 0,584, recall 0,731, F1 0,649. Лучший F1 0,717 достигается при пороге 0,673. Confusion matrix при пороге 0,5: TN=1416, FP=62, FN=32, TP=87.

PR-AUC 0,698 при доле позитива 7,5 процента — это примерно lift 9,3 раза относительно случайного классификатора.

Сравнение с бейзлайном: на сырых признаках baseline ROC-AUC 0,580, RF 0,611, прирост 0,031; с инженерией без истории baseline 0,690, RF 0,746, прирост 0,056; полная модель с историей таргета дает ROC-AUC 0,882.

Ablation по группам признаков: сырые 5 признаков — ROC-AUC 0,611, PR-AUC 0,122; поведение 36 признаков — ROC-AUC 0,746, PR-AUC 0,386; поведение плюс сезон 39 признаков — ROC-AUC 0,749, PR-AUC 0,372; только история таргета 5 признаков — ROC-AUC 0,806, PR-AUC 0,545; все 44 признака — ROC-AUC 0,882, PR-AUC 0,698.

Главный вывод: основной прирост дает синергия «поведение плюс история прошлых опросов». История таргета сама по себе дает ROC-AUC 0,806, поведение без истории — 0,746. Для новых педагогов без истории доступна «честная» поведенческая модель с ROC-AUC около 0,75.

Топ признаков по важности: chars_per_msg_rel, prev_level, past_level_max, past_level_mean, act_msg_char_cnt, chars_per_msg_d4, act_msg_cnt, act_avg_participants_per_hour_lag1.

ИТОГОВАЯ ТАБЛИЦА

RF-модель vs Baseline · сценарий default · таргет burnout_level ≥ 2 · GroupKFold(5) по user_id

① Сравнение с бейзлайном

Метрика	Baseline (default)	RF-модель	Δ / комментарий
ROC-AUC · только сырые (5 фич)	0.580	**0.611**	+0.031
ROC-AUC · + инженерия (без истории)	0.690	**0.746**	+0.056
ROC-AUC · полная (с историей таргета)	—	**0.882**	осн. результат
PR-AUC · полная (7.5% позитива)	—	**0.698**	lift ×9.3
Разброс по фолдам / сидам	0.65 – 0.77	**0.882 ± 0.040**	стабильнее

② Источники сигнала (ablation по группам признаков)

Подмножество признаков	Кол-во	ROC-AUC	PR-AUC
Сырые: event_hours, activity, msg, participants	5	0.611	0.122
Поведение: rolling, rel, d4, lag1	36	0.746	0.386
Поведение + сезон (week, month, tenure)	39	0.749	0.372
Только история таргета (prev_level, past_*)	5	0.806	0.545
Всё (полная модель)	**44**	**0.882**	**0.698**

Вывод: RF-модель превосходит baseline на всех сопоставимых наборах признаков (+0.03...+0.06 ROC-AUC);
дополнительный прирост до 0.88 обеспечивает история прошлых опросов (доступна в проде, но требует явного дисклеймера для новых учителей).

1.5. Аудит утечек данных

Проведены обязательные проверки. rolling/lag смотрят только назад — OK. target соответствует burnout_level >= 2 на той же строке — OK. prev_level и past_level_ используют только прошлое — OK. Shuffle-test: на перемешанном таргете средний ROC-AUC около 0,51, то есть модель не находит ложных закономерностей — OK. Ablation показал, что история дает 0,806, поведение — 0,746, все — 0,882. Разброс по фолдам: ROC-AUC 0,892 плюс-минус 0,040, PR-AUC 0,715 плюс-минус 0,056.

Обнаружена мягкая утечка в _rel для педагогов с tenure < 6: знаменатель использует медиану первых 6 недель, включая будущие значения. Дополнительная проверка _rel_strict, где знаменатель — только прошлая expanding-медиана, дала ROC-AUC 0,875 и PR-AUC 0,694 против 0,882 и 0,698 у старого _rel. Цена строгой версии небольшая, поэтому для продакшена рекомендуется _rel_strict. Для tenure < 6 качество модели резко падает, ROC-AUC около 0,34. Это означает, что на первых 6 неделях педагога модель лучше не применять или выдавать только осторожный поведенческий сигнал.

1.6. Ограничения

Данные синтетические; реальная валидация возможна только на данных ЕЦП. burnout_level — самоотчет, а не объективная истина. Есть шум, MNAR-неответы и усталость от волн опросов. Положительный класс малочислен: 119 позитивов, поэтому разброс метрик по фолдам заметен. Метка доступна только в недели опросов; модель не валидирована на всех неделях. Нельзя делать причинные выводы вида «вечерняя активность вызывает выгорание». Требуются отдельные проверки справедливости, приватности и организационных рисков.

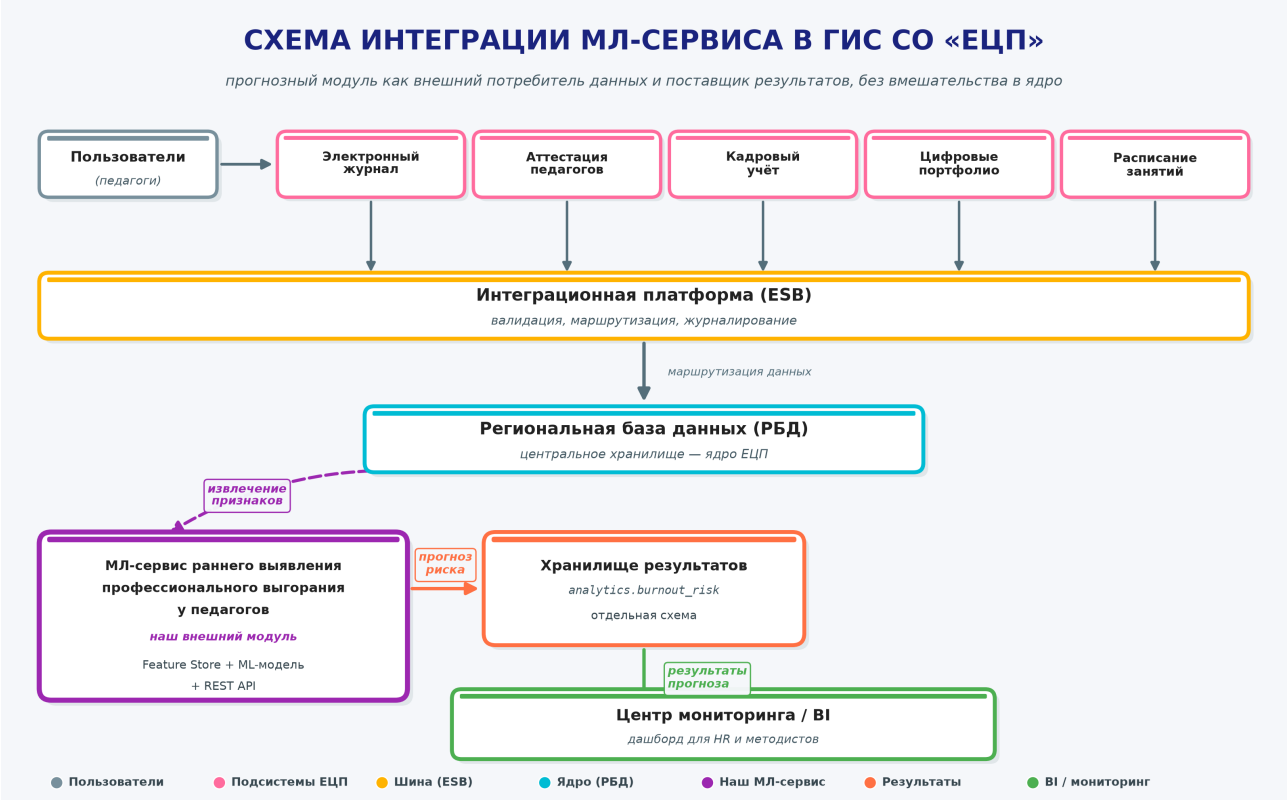
1.7. Выводы и рекомендации

RF-модель превосходит baseline на всех сопоставимых наборах признаков: прирост 0,03–0,06 ROC-AUC. Полная модель достигает ROC-AUC 0,882 и PR-AUC 0,698, что является сильным результатом для синтетического пилота. Основной сигнал — поведение плюс история прошлых опросов; только поведение дает около 0,75 ROC-AUC. Критических утечек не найдено, но _rel лучше заменить на _rel_strict. Для tenure < 6 прогнозы ненадежны — их не стоит использовать для кадровых решений. Признаки week_of_year, month, tenure в финальной модели практически не дают прироста — их можно убрать. Следующий шаг — пилот на реальных данных ЕЦП с комбинированным ground truth: опросы, коллегиальная оценка и интервью с уволившимися.

2. КРАТКАЯ ХАРАКТЕРИСТИКА ML-СЕРВИСА

Название: Система раннего выявления риска профессионального выгорания педагогов в Свердловской области на данных ГИС СО «ЕЦП».

Тип: внешний прогнозный ML-сервис с REST API, интегрируемый через шину ESB. В ядро ЕЦП не вмешивается.



Назначение: выдавать для каждого действующего педагога бинарный риск средне-высокого выгорания burnout_level >= 2 и вероятность риска для приоритизации профилактических мероприятий.

Пользователи: HR-службы, методисты, школьные психологи, региональные органы управления образованием. Сервис — система поддержки решений, а не диагностический инструмент.

Входные данные: кадровый учет; расписание и мероприятия; электронный журнал; цифровые портфолио; лог активности; опросы педагогов; данные об отсутствиях; агрегаты на уровне «педагог × неделя».

Выходные данные: вероятность риска; бинарный класс риска; топ-факторы риска; дата расчета; версия модели; запись в analytics.burnout_risk.

Модель: RandomForest, 44 признака в полной версии, медианная импутация, class_weight balanced_subsample. Для продакшена рекомендуется _rel_strict и отказ от прогнозов при tenure < 6.

Качество на синтетическом пилоте: ROC-AUC 0,882; PR-AUC 0,698; Brier 0,059; recall 0,731 и precision 0,584 при пороге 0,5; максимальный F1 0,717 при пороге 0,673.

Интеграция: подсистемы ЕЦП передают данные через ESB в РБД; ML-сервис состоит из Feature Store, модели и REST API; результаты записываются в хранилище результатов и выводятся в BI-дашборд.

Жизненный цикл: пилот на синтетических данных; переход на реальные данные ЕЦП и опросы; первые 6 месяцев — ежемесячные опросы; интервью с уволившимися; дообучение после каждых 200 увольнений; мониторинг drift, калибровки, fairness и качества.

Ключевые ограничения: синтетическая валидация, самоотчетная метка, мало положительных примеров, риск дрейфа, необходимость защиты персональных данных и запрет на использование сервиса как единственного основания для кадровых решений.